Extensões e Aplicações do Modelo de Regressão Conway-Maxwell-Poisson para Modelagem de Dados de Contagem

Eduardo Elias Ribeiro Junior Orientação: Prof. Dr. Walmes Marques Zeviani

> Projeto de Pesquisa - Laboratório A Departamento de Estatística (DEST) Universidade Federal do Paraná (UFPR)

10 de dezembro de 2015

- 1. Contextualização
- 2. Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

- 1. Contextualização
- Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

- ▶ Disciplinas:
 - Análise de Regressão Linear (CE071 2014/1S)
 - ► Modelos Lineares Generalizados (CE225 2014/2S)
 - Estatística Computacional II (CE089 2014/2S)

- ► Disciplinas:
 - Análise de Regressão Linear (CE071 2014/1S)
 - Modelos Lineares Generalizados (CE225 2014/2S)
 - Estatística Computacional II (CE089 2014/2S)
- ► Trabalho proposto na disciplina CE089:
 - Distribuição Conway-Maxwell-Poisson
 - Simulação, métodos de estimação, função de verossimilhança, inferência estatística

- ► Disciplinas:
 - Análise de Regressão Linear (CE071 2014/1S)
 - Modelos Lineares Generalizados (CE225 2014/2S)
 - Estatística Computacional II (CE089 2014/2S)
- ► Trabalho proposto na disciplina CE089:
 - Distribuição Conway-Maxwell-Poisson
 - Simulação, métodos de estimação, função de verossimilhança, inferência estatística
- Sugestão de leitura do artigo The Gamma-count distribution in the analysis of experimental underdispersed data por Zeviani et al., (2014):
 - Apresentação da distribuição Count-gama (concorrente à Conway-Maxwell-Poisson)
 - Análise de dados utilizando um modelo de regressão
 - Discussão de aspectos inferenciais

- 1. Contextualização
- 2. Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

Dados de contagem

Representam o número de ocorrências de um evento de interesse em um domínio específico.

Se Y é uma v.a de contagem, $y \in \mathbb{Z}_+$, ou seja, y = 0, 1, 2, ...

Dados de contagem

Representam o número de ocorrências de um evento de interesse em um domínio específico.

Se Y é uma v.a de contagem, $y \in \mathbb{Z}_+$, ou seja, y = 0, 1, 2, ...

Exemplos:

- Número de filhos por casal;
- Número de indivíduos infectados por uma doença;
- Número de insetos mortos após k dias da aplicação de inseticida;
- **.**..

Modelos de regressão

Permitem a inclusão de variáveis independentes (covariáveis) para:

- Descrever a relação entre a variável resposta e as variáveis preditoras; e
- Realizar predições por meio do modelo estabelecido.

Modelos de regressão

Permitem a inclusão de variáveis independentes (covariáveis) para:

- Descrever a relação entre a variável resposta e as variáveis preditoras; e
- Realizar predições por meio do modelo estabelecido.

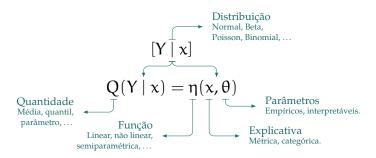


Figure 1: Representação esquemática de um modelo de regressão

Modelo Poisson

Densidade de probabilidade

$$Pr(Y = y) = \frac{\lambda^y}{y!e^{\lambda}} \quad y \in \mathbb{Z}_+$$
 (1)

Modelo Poisson

Densidade de probabilidade

$$Pr(Y = y) = \frac{\lambda^y}{y!e^{\lambda}} \quad y \in \mathbb{Z}_+$$
 (1)

Propriedades

- $P(Y=y-1) = \frac{y}{\lambda}$
- ightharpoonup $E(Y) = \lambda$
- $V(Y) = \lambda$

Equidispersão

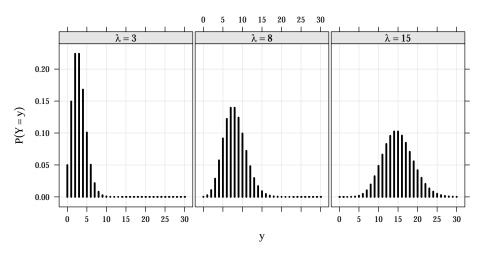


Figure 2: Densidade de probabilidade da distribuição Poisson

Abordagens para fuga da suposição

► Modelo quase-Poisson

$$V(Y) = \varphi V(\mu)$$

Nesta abordagem estima-se ϕ separadamente:

- ▶ Produz as mesmas estimativas pontuais do que o modelo Poisson;
- Corrige os erros-padrão das estimativas;
- ▶ Não é possível recuperar a verdadeira distribuição de Y;

Abordagens para fuga da suposição

► Modelo quase-Poisson

$$V(Y) = \varphi V(\mu)$$

Nesta abordagem estima-se ϕ separadamente:

- Produz as mesmas estimativas pontuais do que o modelo Poisson;
- Corrige os erros-padrão das estimativas;
- Não é possível recuperar a verdadeira distribuição de Y;

Modelo de efeitos aleatórios

$$g(\mu) = X\beta + Z\underline{b}$$

Onde b são efeitos aleatórios, variáveis não observadas (latentes) provenientes de uma distribuição de probabilidades.

- Contemplam a estrutura de delineamento experimentada;
- Capturam (somente) a variabilidade extra especificada pelo modelo;
- São computacionalmente intensivos;

Modelo COM-Poisson

Densidade de probabilidade

$$Pr(Y = y \mid \lambda, \nu) = \frac{\lambda^{y}}{(y!)^{\nu} Z(\lambda, \nu)} \quad y \in \mathbb{Z}_{+}$$
 (2)

onde
$$Z(\lambda, \nu) = \sum_{j=0}^{\infty} \frac{\lambda^{j}}{(j!)^{\nu}}$$
; $e \qquad \lambda > 0 \ e \ \nu \geqslant 0$

Modelo COM-Poisson

Densidade de probabilidade

$$Pr(Y = y \mid \lambda, \nu) = \frac{\lambda^{y}}{(y!)^{\gamma} Z(\lambda, \nu)} \quad y \in \mathbb{Z}_{+}$$
 (2)

onde
$$Z(\lambda, \nu) = \sum_{j=0}^{\infty} \frac{\lambda^{j}}{(j!)^{\nu}}$$
; $e \quad \lambda > 0 \ e \ \nu \geqslant 0$

Propriedades

- $P(Y=y-1) = \frac{y^{\nu}}{\lambda}$
- $\blacktriangleright \ E(Y) \approx \lambda^{\frac{1}{\nu}} \tfrac{\nu 1}{2\nu}$
- $V(Y) \approx \frac{1}{2}E(Y)$
- ightharpoonup $E(Y^{\nu}) = \lambda$

Modelo COM-Poisson

Densidade de probabilidade

$$Pr(Y = y \mid \lambda, \nu) = \frac{\lambda^{y}}{(y!)^{\nu} Z(\lambda, \nu)} \quad y \in \mathbb{Z}_{+}$$
 (2)

onde
$$Z(\lambda, \nu) = \sum_{j=0}^{\infty} \frac{\lambda^{j}}{(j!)^{\nu}}$$
; $e \qquad \lambda > 0 \; e \; \nu \geqslant 0$

Propriedades

- $P(Y=y-1) = \frac{y^{\nu}}{\lambda}$
- $\blacktriangleright \ E(Y) \approx \lambda^{\frac{1}{\nu}} \frac{\nu 1}{2\nu}$
- $V(Y) \approx \frac{1}{\nu} E(Y)$
- \triangleright E(Y $^{\vee}$) = λ

Casos particulares

- Distribuição Poisson, quando ν = 1
- ▶ Distribuição Bernoulli, quando $v \to \infty$
- Distribuição Geométrica, quando v = 0, $\lambda < 1$

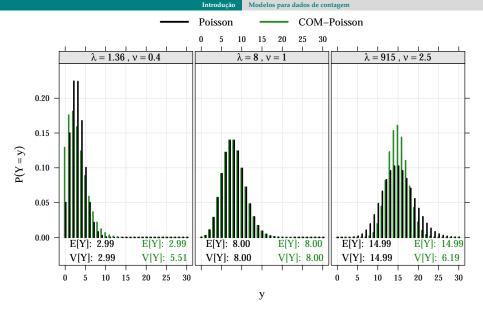


Figure 3: Densidade de probabilidade da distribuição COM-Poisson comparada com a Poisson

Extensões do modelo de regressão COM-Poisson

Excesso de zeros

O mecanismo gerador das variáveis aleatórias de contagem é proveniente de duas distribuições.

Extensões do modelo de regressão COM-Poisson

Excesso de zeros

O mecanismo gerador das variáveis aleatórias de contagem é proveniente de duas distribuições.

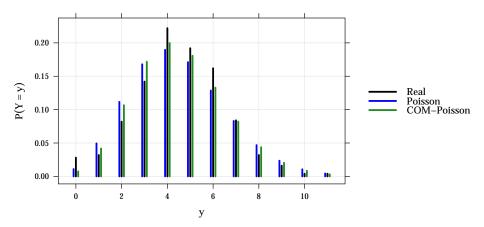


Figure 4: Contagens que apresentam excesso de zeros

Modelos para dados de contagem

Extensões do modelo de regressão COM-Poisson

► Efeitos aleatórios

Correlação entre grupos de indivíduos induzida pelo delineamento experimental ou estrutura do problema.

Extensões do modelo de regressão COM-Poisson

Efeitos aleatórios

Correlação entre grupos de indivíduos induzida pelo delineamento experimental ou estrutura do problema.

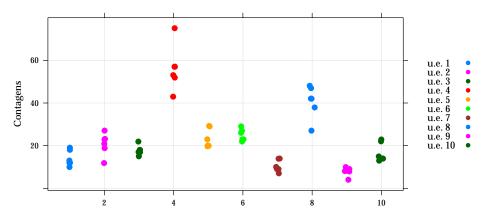


Figure 5: Contagens que apresentam um efeito aleatório da unidade experimental (u.e.)

- Contextualização
- Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

Objetivos gerais

► Apresentar o modelo de regressão COM-Poisson com discussão sobre aspectos inferenciais;

Objetivos gerais

- Apresentar o modelo de regressão COM-Poisson com discussão sobre aspectos inferenciais;
- Estender as aplicações para situações específicas como efeitos aleatórios e excesso de zeros; e

Objetivos gerais

- Apresentar o modelo de regressão COM-Poisson com discussão sobre aspectos inferenciais;
- Estender as aplicações para situações específicas como efeitos aleatórios e excesso de zeros; e
- Contribuir para a comunidade Estatística, principalmente aplicada, com aplicações e discussões de uma abordagem paramétrica flexível para dados de contagem.

► Apresentar e discutir aspectos da distribuição COM-Poisson para modelagem de dados de contagem;

- Apresentar e discutir aspectos da distribuição COM-Poisson para modelagem de dados de contagem;
- Avaliar as propriedades de soluções numéricas para i) cálculo da densidade de probabilidade e ii) estimação dos modelos de regressão de efeito fixo;

- Apresentar e discutir aspectos da distribuição COM-Poisson para modelagem de dados de contagem;
- Avaliar as propriedades de soluções numéricas para i) cálculo da densidade de probabilidade e ii) estimação dos modelos de regressão de efeito fixo;
- ▶ Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar efeitos aleatórios;

- Apresentar e discutir aspectos da distribuição COM-Poisson para modelagem de dados de contagem;
- Avaliar as propriedades de soluções numéricas para i) cálculo da densidade de probabilidade e ii) estimação dos modelos de regressão de efeito fixo;
- ▶ Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar efeitos aleatórios;
- ▶ Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar contagens com excesso de zeros;

- Apresentar e discutir aspectos da distribuição COM-Poisson para modelagem de dados de contagem;
- Avaliar as propriedades de soluções numéricas para i) cálculo da densidade de probabilidade e ii) estimação dos modelos de regressão de efeito fixo;
- Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar efeitos aleatórios;
- Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar contagens com excesso de zeros;
- ▶ Fazer aplicação do modelo COM-Poisson e suas extensões desenvolvidas à dados reais e simulados; e

- Apresentar e discutir aspectos da distribuição COM-Poisson para modelagem de dados de contagem;
- Avaliar as propriedades de soluções numéricas para i) cálculo da densidade de probabilidade e ii) estimação dos modelos de regressão de efeito fixo;
- Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar efeitos aleatórios;
- Propor e implementar a extensão do modelo de regressão COM-Poisson para acomodar contagens com excesso de zeros;
- Fazer aplicação do modelo COM-Poisson e suas extensões desenvolvidas à dados reais e simulados; e
- ▶ Fazer comparações com as abordagens já utilizadas para as situações estudadas: Poisson, Quase-Poisson, Binomial Negativo, Poisson de efeito aleatório.

- Contextualização
- Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

Conjunto de dados

A pesquisa tem como um dos objetivos a avaliação do método, portanto pretende-se utilizar vários conjuntos de dados.

Dados de desfolha

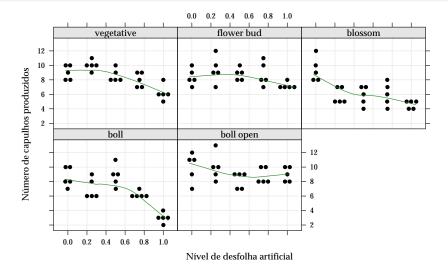


Figure 6: Número de capulhos produzidos pelo nível de desfolha estratificado por estágio da planta

Resursos Computacionais



Pacotes:

- COMPoissonReg (SELLERS; LOTZE, 2011);
- compoisson (DUNN, 2012);
- CompGLM (POLLOCK, 2014);
- Bibliotecas para elaboração de gráficos e otimização de funções;

Modelos para excesso de zeros

► Modelos de Barreira (condicionais ou truncados)

Hurdle models

$$Pr(Y = y) = \begin{cases} \pi & \text{se } y = 0, \\ (1 - \pi) \frac{f_*(y)}{1 - f_*(0)} & \text{se } y = 1, 2, \dots \end{cases}$$
 (3)

Modelos para excesso de zeros

► Modelos de Barreira (condicionais ou truncados)

Hurdle models

$$Pr(Y = y) = \begin{cases} \pi & \text{se } y = 0, \\ (1 - \pi) \frac{f_*(y)}{1 - f_*(0)} & \text{se } y = 1, 2, \dots \end{cases}$$
 (3)

Modelos Inflacionados de Zeros (mistura) e.g. Zero Inflated Poisson Regression (ZIP)

$$Pr(Y = y) = \begin{cases} \pi + (1 - \pi)f_*(0) & \text{se } y = 0, \\ (1 - \pi)f_*(y) & \text{se } y = 1, 2, \dots \end{cases}$$
(4)

Modelos para excesso de zeros

► Modelos de Barreira (condicionais ou truncados)

Hurdle models

$$Pr(Y = y) = \begin{cases} \pi & \text{se } y = 0, \\ (1 - \pi) \frac{f_*(y)}{1 - f_*(0)} & \text{se } y = 1, 2, \dots \end{cases}$$
 (3)

Modelos Inflacionados de Zeros (mistura) e.g. Zero Inflated Poisson Regression (ZIP)

$$Pr(Y = y) = \begin{cases} \pi + (1 - \pi)f_*(0) & \text{se } y = 0, \\ (1 - \pi)f_*(y) & \text{se } y = 1, 2, \dots \end{cases}$$
(4)

Modelos de efeitos aleatórios

$$\begin{aligned} Y \mid b \sim f_*(\mu, \varphi) \\ g(\mu) = & \beta_0 + b_i \\ b_i \sim & N(0, \sigma^2) \end{aligned}$$

$$Pr(Y = y) = \int_{-\infty}^{\infty} [Y \mid X, b_i][b_i] db_i$$
 (5)

Modelos de efeitos aleatórios

$$Y \mid b \sim f_*(\mu, \phi)$$

$$g(\mu) = \beta_0 + b_i$$

$$b_i \sim N(0, \sigma^2)$$

$$Pr(Y = y) = \int_{-\infty}^{\infty} [Y \mid X, b_i][b_i] db_i$$
 (5)

- ▶ Métodos de integração numérica, discutidos em Ribeiro Jr et al., (2012)
 - Aproximação de Laplace
 - Quadratura Gaussiana
 - Monte Carlo (e.g. MCMC)

Métodos de estimação

Máxima Verossimilhança

$$L(\underline{\theta} \mid \underline{Y}) = \prod_{i=1}^{n} f_*(y_i \mid \underline{\theta})$$

$$\underline{\hat{\theta}} \implies \text{max}(\text{log}(L(\underline{\theta} \,|\, \underline{Y})))$$

Métodos de estimação

Máxima Verossimilhança

$$L(\underline{\theta} \mid \underline{Y}) = \prod_{i=1}^{n} f_*(y_i \mid \underline{\theta})$$

$$\underline{\hat{\theta}} \implies \mathsf{max}(\mathsf{log}(\mathsf{L}(\underline{\theta} \,|\, \underline{Y})))$$

► Mínimos Quadrados Ponderados Iterativamente Iterative Reweighted Least Squares (IRLS)

$$\begin{split} & \text{dll/d} \beta_j \approx (y_i - \text{E}[Y_i] x_{ij}) \\ & \text{dll/d} \nu \approx \text{log}(y_i!) + \text{E}[\text{log}(Y_i!)] \end{split}$$

Métodos de estimação

Máxima Verossimilhança

$$L(\underline{\theta} \mid \underline{Y}) = \prod_{i=1}^{n} f_*(y_i \mid \underline{\theta})$$

$$\underline{\hat{\theta}} \implies \mathsf{max}(\mathsf{log}(\mathsf{L}(\underline{\theta} \,|\, \underline{Y})))$$

► Mínimos Quadrados Ponderados Iterativamente Iterative Reweighted Least Squares (IRLS)

$$\begin{split} & \text{dll/d} \beta_j \approx (y_i - \text{E}[Y_i] x_{ij}) \\ & \text{dll/d} \nu \approx \text{log}(y_i!) + \text{E}[\text{log}(Y_i!)] \end{split}$$

Critérios para Comparação

 Critério de Informação de Akaike Akaike Information Criterion (AIC)

$$AIC = 2k - 2\log(L(\hat{\underline{\theta}} \mid \underline{Y}))$$

Critérios para Comparação

► Critério de Informação de Akaike Akaike Information Criterion (AIC)

$$AIC = 2k - 2\log(L(\hat{\underline{\theta}} \mid \underline{Y}))$$

 Critério de Informação Bayesiano Bayesian Information Criterion (BIC)

$$BIC = \log(n)k - 2\log(L(\hat{\underline{\theta}} \mid \underline{Y}))$$

Critérios para Comparação

► Critério de Informação de Akaike Akaike Information Criterion (AIC)

$$AIC = 2k - 2\log(L(\hat{\underline{\theta}} \mid \underline{Y}))$$

 Critério de Informação Bayesiano Bayesian Information Criterion (BIC)

$$BIC = \log(n)k - 2\log(L(\hat{\underline{\theta}} \mid \underline{Y}))$$

► Teste de razão de verossimilhanças (TRV)

$$\begin{split} \text{TRV} &= 2\text{log}(L(\underline{\hat{\theta}}_p,\underline{y})) - \text{log}(L(\underline{\hat{\theta}}_q),\underline{y}) \\ \text{TRV} &\sim \chi^2_{p-q} \end{split}$$

Sumário

- Contextualização
- 2. Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

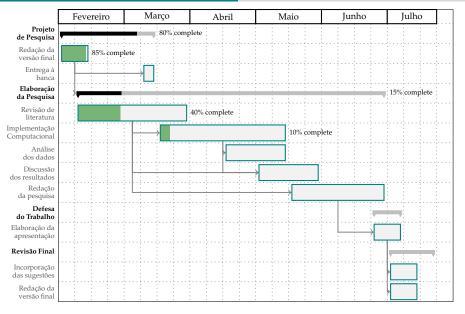


Figure 7: Cronograma de atividades para 2016

Sumário

- Contextualização
- 2. Introdução
- 3. Objetivos
- 4. Materiais e Métodos
- 5. Cronograma
- 6. Bibliografia

Referências

KING, G. Variance Specification in Event Count Models: From Restrictive Assumptions to a Generalized Estimator. **American Journal of Political Science**, v. 33, n. 3, p. 762—784, ago. 1989.

NELDER, J. A.; WEDDERBURN, R. W. M. Generalized Linear Models. **Journal of the Royal Statistical Society. Series A (General)**, v. 135, p. 370–384, 1972.

PAULA, G. A. **Modelos de regressão com apoio computacional**. Traducao. [s.l.] IME-USP São Paulo, 2013.

RIBEIRO JR, P. J. et al. **Métodos computacionais para inferência com aplicações em R**20° simpósio nacional de probabilidade e estatística. **Anais**...2012Disponível em: http://leg.ufpr.br/doku.php/cursos:mcie

SELLERS, K. F.; SHMUELI, G. A flexible regression model for count data. **Annals of Applied Statistics**, v. 4, n. 2, p. 943–961, 2010.

SHMUELI, G. et al. A useful distribution for fitting discrete data: Revival of the Conway-Maxwell-Poisson distribution. **Journal of the Royal Statistical Society. Series C: Applied Statistics**, v. 54, n. 1, p. 127–142, 2005.

ZEVIANI, W. M. et al. The Gamma-count distribution in the analysis of experimental underdispersed data. **Journal of Applied Statistics**, n. October, p. 1–11, 2014.