# Extensões e Aplicações do Modelo de Regressão Conway-Maxwell-Poisson para Modelagem de Dados de Contagem

Eduardo Elias Ribeiro Junior Orientação: Prof. Dr. Walmes Marques Zeviani

> Trabalho de Conclusão de Curso - Laboratório B Departamento de Estatística (DEST) Universidade Federal do Paraná (UFPR)

> > 28 de junho de 2016

#### Sumário

- 1. Introdução
- 2. Objetivos
- 3. Materiais e Métodos
- 4. Resultados e Discussões
- 5. Considerações finais

#### 1

# Introdução

## Dados de contagem

# 1 11 111 1111 1111

São variáveis aleatórias aleatórias que representam o número de ocorrências de um evento em um dominío discreto ou contínuo.

Se Y é uma variável aleatória de contagem, y = 0, 1, 2, ...

#### **Exemplos:**

- Número de filhos por casal;
- Número de indivíduos infectados por uma doença;
- Número de posts em uma rede social durante um dia;
- Número de frutos produzidos;
- **.** . .

## Análise de dados de contagem

- Modelos de regressão Gaussianos com dados transformados
  - Dificultam a interpretação dos resultados;
  - Não contemplam a natureza discreta da variável;
  - Não contemplam a relação média e variância;
  - Transformação logarítmica é problemática para valores 0.
- Modelos de regressão Poisson (NELDER; WEDDERBURN, 1972)
  - Fiel a natureza dos dados;
  - Contempla a relação média e variância;
  - Suposição de equidispersão.

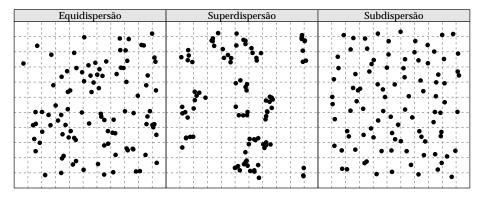


Figura 1: Ilustração de processos pontuais que levam a contagens com diferentes níveis de dispersão.

## Distribuições de probabilidades para dados de contagem

Com base em WINKELMANN (2008) e KOKONENDJI (2014)

Tabela 1: Distribuições de probabilidades para dados de contagem

Distribuição	Contempla a característica de				
Distribuição	Equidispersão	Superdispersão	Subdispersão		
Poisson	<b>√</b>				
Binomial Negativa	$\checkmark$	$\checkmark$			
Inverse Gaussian Poisson	$\checkmark$	$\checkmark$			
Compound Poisson	$\checkmark$	$\checkmark$			
Poisson Generalizada	$\checkmark$	$\checkmark$	$\checkmark$		
Gamma-Count	$\checkmark$	$\checkmark$	$\checkmark$		
COM-Poisson	$\checkmark$	$\checkmark$	$\checkmark$		
Katz	$\checkmark$	$\checkmark$	$\checkmark$		
Poisson Polynomial	$\checkmark$	$\checkmark$	$\checkmark$		
Double-Poisson	$\checkmark$	$\checkmark$	$\checkmark$		
Lagrangian Poisson	$\checkmark$	$\checkmark$	$\checkmark$		

## Distribuições de probabilidades para dados de contagem

Com base em WINKELMANN (2008) e KOKONENDJI (2014)

Tabela 1: Distribuições de probabilidades para dados de contagem

Distribuição	Contempla a característica de				
Distribuição	Equidispersão	Superdispersão	Subdispersão		
Poisson	✓				
Binomial Negativa	$\checkmark$	$\checkmark$			
Inverse Gaussian Poisson	✓	✓			
Compound Poisson	$\checkmark$	$\checkmark$			
Poisson Generalizada	$\checkmark$	$\checkmark$	$\checkmark$		
Gamma-Count	$\checkmark$	$\checkmark$	$\checkmark$		
COM-Poisson	$\checkmark$	✓	$\checkmark$		
Katz	✓	✓	✓		
Poisson Polynomial	$\checkmark$	$\checkmark$	$\checkmark$		
Double-Poisson	$\checkmark$	$\checkmark$	$\checkmark$		
Lagrangian Poisson	$\checkmark$	$\checkmark$	$\checkmark$		

## Distribuição COM-Poisson

Proposta por CONWAY; MAXWELL (1962).

Função massa de probabilidade

$$\Pr(Y = y \mid \lambda, \nu) = \frac{\lambda^{y}}{(y!)^{\nu} Z(\lambda, \nu)}, \qquad Z(\lambda, \nu) = \sum_{j=0}^{\infty} \frac{\lambda^{j}}{(j!)^{\nu}}$$
(1)

- Não tem expressão fechada para média e variância;
- Apresenta distribuições bastante conhecidas como casos particulares:
  - ▶ Poisson  $\nu = 1$ ;
  - ▶ Bernoulli  $\nu \rightarrow \infty$ ;
  - Geométrica  $\nu = 0$  e  $\lambda < 1$ .

## Distribuição COM-Poisson

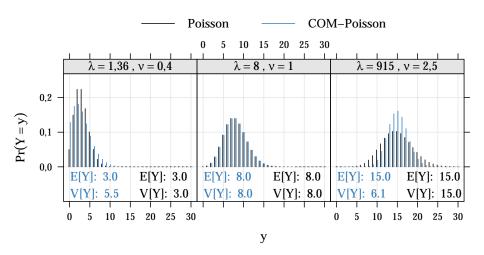


Figura 2: Probabilidades pela distribuição COM-Poisson.

## Relações média-variância

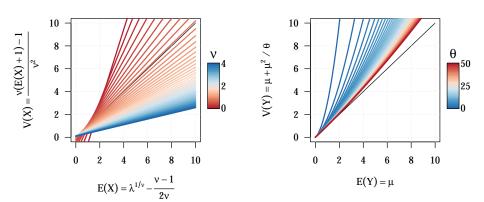


Figura 3: Relações Média e Variância COM-Poisson e Binomial Negativa.

2

# **Objetivos**

## Objetivos gerais

Colaborar com a literatura estatística brasileira, no que diz respeito a dados de contagem:

- Apresentando e explorando o modelo de regressão COM-Poisson;
- Estendendo o modelo para modelagem de excesso de zeros e inclusão de efeitos aleatórios;
- Discutindo o desempenho do modelo via análise de dados reais;
- Disponibilizando os recursos computacionais para ajuste dos modelos, em formato de pacote R.

2

## Materiais e Métodos

#### 3.1

## Materiais e Métodos **Materiais**

## Conjuntos de dados

#### Seis conjuntos de dados analisados:

- Capulhos de algodão sob desfolha artificial;
- Produtividade de algodão sob infestação de Mosca-branca;
- Produtividade de soja sob umidade e adubação potássica;
- Ocorrência de ninfas de Mosca-branca em lavoura de soja;
- Peixes capturados por visitantes de um parque Estadual;
- Número de nematoides em raizes de feijoeiro.

## Conjuntos de dados

#### Seis conjuntos de dados analisados:

- Capulhos de algodão sob desfolha artificial;
- Produtividade de algodão sob infestação de Mosca-branca;
- Produtividade de soja sob umidade e adubação potássica;
- Ocorrência de ninfas de Mosca-branca em lavoura de soja;
- Peixes capturados por visitantes de um parque Estadual;
- ▶ Número de nematoides em raizes de feijoeiro.

## **Recursos Computacionais**

Software R versão 3.3.0. Principais pacotes:

- MASS 7.3.45: ajuste dos modelos binomial negativo;
- pscl 1.4.9: modelagem de excesso de zeros;
- lme4 1.1.12: ajuste dos modelos Poisson com efeito aleatório Normal;
- ▶ bbmle 1.0.18: ajuste de modelos via máxima verossimilhança.

#### 3.2

## Materiais e Métodos **Métodos**

## Estimação via máxima verossimilhança

- Escreva a função de verossimilhança  $\mathcal{L}(\Theta \mid \underline{y})$
- ② Tome seu logaritmo  $\ell(\Theta \mid \underline{y})$
- As estimativas dos parâmetros são

$$\hat{\Theta} = \arg\max_{\Theta} \ell(\Theta \mid \underline{y})$$

- ▶ Algoritmo IWLS (*Interactive Weigthed Leasts Squares*) para os modelos Poisson, Binomial Negativo e Quasi-Poisson.
- Método BFGS para os modelos COM-Poisson.

## Verossimilhança do modelo COM-Poisson

- Reparametrizando  $\phi = \log(\nu)$ 
  - $\phi < 0 \Rightarrow$  Superdispersão
  - $\phi = 0 \Rightarrow$  Equidispersão
  - $\phi > 0 \Rightarrow$  Subdispersão

#### Log-verossimilhança

$$\ell(\phi, \beta \mid \underline{y}) = \sum_{i=1}^{n} y_i \log(\lambda_i) - e^{\phi} \sum_{i=1}^{n} \log(y!) - \sum_{i=1}^{n} \log(Z(\lambda_i, \phi))$$
 (2)

em que  $\lambda_i = e^{X_i \beta}$ , com  $X_i$  o vetor  $(x_{i1}, x_{i2}, \dots x_{ip})$  de covariáveis da i-ésima observação, e  $(\beta, \phi) \in \mathbb{R}^{p+1}$ .

## Verossimilhança do modelo Hurdle COM-Poisson

- ▶  $\underline{\pi} = \frac{\exp(G\gamma)}{1 + \exp(G\gamma)}$  a probabilidade de contagem nula.
- $\underline{\lambda} = \exp(X\beta)$  o parâmetro de locação da distribuição COM-Poisson truncada.

#### Verossimilhança

$$\mathcal{L}(\phi, \beta, \gamma \mid \underline{y}) = \mathbb{1}[\underline{\pi}] \cdot (1 - \mathbb{1}) \left[ (1 - \underline{\pi}) \left( \frac{\underline{\lambda}^{y}}{(y!)^{e^{\phi}} Z(\underline{\lambda}, \phi)} \right) \left( 1 - \frac{1}{Z(\underline{\lambda}, \phi)} \right) \right]$$
(3)

em que 1 é uma função indicadora para y = 0

## Verossimilhança do modelo misto COM-Poisson

$$Y_{ij} \mid b_{i}, X_{ij} \sim \text{COM-Poisson}(\mu_{ij}, \phi)$$
  
$$g(\mu_{ij}) = X_{ij}\beta + Z_ib_i$$
  
$$b \sim \text{Normal}(0, \Sigma)$$

Métodos

#### Verossimilhança

$$\mathcal{L}(\phi, \Sigma, \beta \mid \underline{y}) = \prod_{i=1}^{m} \int_{\mathbb{R}^{q}} \left( \prod_{j=1}^{n_{i}} \frac{\underline{\lambda}^{y}}{(y!)^{e^{\phi}} Z(\underline{\lambda}, \phi)} \right) \cdot (2\pi)^{q/2} |\Sigma| \exp\left(-\frac{1}{2} b^{t} \Sigma^{-1} b\right) db_{i}$$
(4)

*m* : o número de grupos que compartilham do mesmo efeito aleatório; *q* : o número de efeitos aleatórios (intercepto aleatório, inclinação e intercepto aleatórios, etc.); e

 $n_i$ : o número de observações no i-ésimo grupo.

1

# Resultados e Discussões

#### 4.1

## Resultados e Discussões **Pacote R**

## cmpreg: Ajuste de Modelos de Regressões COM-Poisson

Implementação em R de um *framework* para ajuste dos modelos de regressão COM-Poisson, pacote cmpreg.

```
## Pode ser instalado do GitHub
devtools::install_git("https://github.com/JrEduardo/cmpreg.git")
library(cmpreg)
## Regressão (efeitos fixos)
cmp(v ~ preditor, data = data)
## Regressão com componente de barreira
hurdlecmp(y ~ count_pred | zero_pred, data = data)
## Regressão (efeitos aleatórios)
mixedcmp(y ~ count_pred + (1 | ind.ranef), data = data)
```

#### 4.2

## Resultados e Discussões **Produtividade de algodão**

## Experimento

Conduzido na UFGD em casa de vegetação (MARTELLI et al., 2008).

- Objetivo: avaliar o impacto da praga Mosca-branca na produção de algodão;
- Delineamento: inteiramente casualizado com cinco repetições
- Unidade amostral: vaso com duas plantas;
- Covariável experimental:
  - Tempo de exposição das plantas à praga, em dias (dexp);
- Variáveis resposta:
  - Número de capulhos produzidos;
  - Número de estruturas reprodutivas;
  - Número de nós.

## Modelagem

#### Preditores considerados:

- Preditor 1:  $g(\mu_i) = \beta_0$
- ▶ Preditor 2:  $g(\mu_i) = \beta_0 + \beta_1 \text{dexp}_i$
- Preditor 3:  $g(\mu_i) = \beta_0 + \beta_1 \operatorname{dexp}_i + \beta_2 \operatorname{dexp}_i^2$

#### Modelos concorrentes:

- $\triangleright$  Poisson( $\mu_i$ )
- ▶ COM-Poisson( $\lambda_i$ ,  $\phi$ )
- Quasi-Poisson( $\mu_i$ ,  $\sigma^2$ )

## Medidas de ajuste

Tabela 2: Medidas de ajuste para avaliação e comparação

	Poisson			C	COM-Poisson		Quasi-Poisson	
np	$\ell$	AIC	$P(>\chi^2)$	$\ell$	AIC	$P(>\chi^2)$	deviance	P(> F)
Número de capulhos produzidos								
1	-105,27	212,55		-92,05	188,09		20,80	
2	-105,03	214,05	0,4832	-91,31	188,62	0,2254	20,31	0,2296
3	-104,44	214,88	0,2782	-89,47	186,95	0,0552	19,13	0,0616
Número de estruturas reprodutivas				_				
1	-104,74	211,49		-86,41	176,82		16,23	
2	-104,27	212,54	0,3320	-84,59	175,18	0,0566	15,29	0,0622
3	-104,06	214,12	0,5157	-83,73	175,47	0,1898	14,87	0,2071
Número de nós da planta					_			
1	-143,79	289,59		-120,58	245,16		12,69	
2	-143,48	290,95	0,4253	-119,03	244,06	0,0787	12,05	0,0851
3	-142,95	291,89	0,3037	-116,27	240,54	0,0188	11,00	0,0223

## Medidas de ajuste

Tabela 2: Medidas de ajuste para avaliação e comparação

	Poisson			C	COM-Poisson		Quasi-Poisson	
np	$\ell$	AIC	$P(>\chi^2)$	$\ell$	AIC	$P(>\chi^2)$	deviance	P(> F)
Número de capulhos produzidos								
1	-105,27	212,55		-92,05	188,09		20,80	
2	-105,03	214,05	0,4832	-91,31	188,62	0,2254	20,31	0,2296
3	-104,44	214,88	0,2782	-89,47	186,95	0,0552	19,13	0,0616
Nún	Número de estruturas reprodutivas							
1	-104,74	211,49		-86,41	176,82		16,23	
2	-104,27	212,54	0,3320	-84,59	175,18	0,0566	15,29	0,0622
3	-104,06	214,12	0,5157	-83,73	175,47	0,1898	14,87	0,2071
Número de nós da planta								
1	-143,79	289,59		-120,58	245,16		12,69	
2	-143,48	290,95	0,4253	-119,03	244,06	0,0787	12,05	0,0851
3	-142,95	291,89	0,3037	-116,27	240,54	0,0188	11,00	0,0223

## Avaliação da dispersão

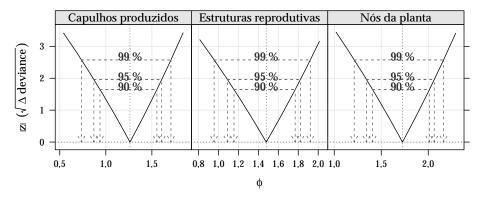


Figura 4: Perfis de log-verossimilhança para o parâmetro de precisão da COM-Poisson.

## Avaliação da matriz de covariância

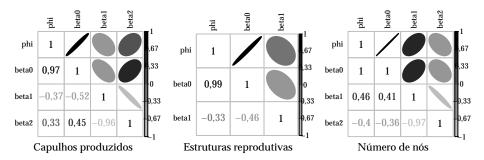


Figura 5: Imagem da matriz de correlação entre os parâmetros do modelo COM-Poisson.

## Valores preditos

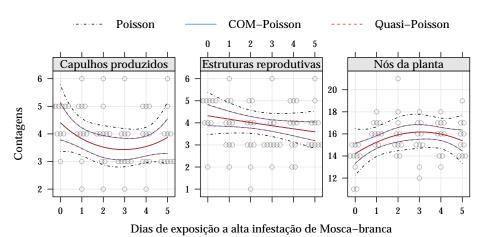


Figura 6: Curva dos valores preditos com intervalo de confiança de (95%) como função dos dias de exposição a alta infestação de Mosca-branca.

#### 4.3

## Resultados e Discussões Ocorrência de ninfas de Mosca-branca

## **Experimento**

#### Conduzido na UFGD em casa de vegetação (SUEKANE, 2011).

- Objetivo: avaliar a ocorrência de mosca-branca nas diferentes cultivares de soja;
- Delineamento: blocos casualizados, quatro blocos;
- Unidade experimental: dois vasos com duas plantas;
- Covariáveis experimentais:
  - Indicadora de bloco, I, II, III e IV, (bloco);
  - ▶ Dias decorridos após a primeira avaliação, 0, 8, 13, 22, 31 e 38 dias, (dias);
  - Indicadora de cultivar de soja, BRS 239, BRS 243 RR, BRS 245 RR, BRS246 RR, (cult);
- Variável resposta:
  - Número de ninfas de Mosca-branca nos folíolos dos terços superior, médio e inferior.

### Modelagem

#### Preditores considerados:

- ▶ Preditor 1:  $g(\mu_{ijk}) = \beta_0 + \tau_i + \gamma_j + \delta_k$
- ► Preditor 2:  $g(\mu_{ijk}) = \beta_0 + \tau_i + \gamma_j + \delta_k + \alpha_{jk}$

 $\tau_i$  é o efeito do i-ésimo bloco, i=1,2,3,4  $\gamma_j$  o efeito da j-ésima cultivar, j=1,2,3,4  $\delta_k$  o efeito do k-ésimo nível de dias,  $k=1,2,\ldots,6$  e  $\alpha_{ik}$  o efeito da interação entre a j-ésima cultivar e o k-ésimo nível de dias

#### Modelos concorrentes:

- ▶ Poisson( $\mu_{iik}$ )
- ► COM-Poisson( $\lambda_{ijk}$ ,  $\phi$ )
- ▶ Binomial Negativo( $\mu_{ijk}$ ,  $\theta$ )
- Quasi-Poisson( $\mu_{ijk}$ ,  $\sigma^2$ )

Tabela 3: Medidas de ajuste para avaliação e comparação

Poisson	np	$\ell$	AIC	$2(\text{diff }\ell)$	diff np	$P(>\chi^2)$	
Preditor 1 Preditor 2	12 27	-922,98 -879,23	1869,96 1812,46	87,50	15	0,0000	
COM-Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{\phi}$
Preditor 1 Preditor 2	13 28	-410,44 -407,15	846,89 870,30	6,59	15	0,9680	-3,08 -2,95
Binomial Neg.	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{ heta}$
Preditor 1 Preditor 2	13 28	-406,16 -400,55	838,31 857,10	11,21	15	0,7376	3,44 3,99
Quase-Poisson	np	deviance	AIC	F	diff np	P(>F)	$\hat{\sigma}^2$
Preditor 1 Preditor 2	12 27	1371,32 1283,82		0,31	15	0,9932	17,03 19,03

Tabela 3: Medidas de ajuste para avaliação e comparação

Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	
Preditor 1	12	-922,98	1869,96				
Preditor 2	27	-879,23	1812,46	87,50	15	0,0000	
COM-Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{\phi}$
Preditor 1	13	-410,44	846,89				-3,08
Preditor 2	28	-407,15	870,30	6,59	15	0,9680	-2,95
Binomial Neg.	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{ heta}$
Preditor 1	13	-406,16	838,31				3,44
Preditor 2	28	-400,55	857,10	11,21	15	0,7376	3,99
Quase-Poisson	np	deviance	AIC	F	diff np	P(>F)	$\hat{\sigma}^2$
Preditor 1	12	1371,32					17,03
Preditor 2	27	1283,82		0,31	15	0,9932	19,03

### Avaliando a dispersão e convergência de Z

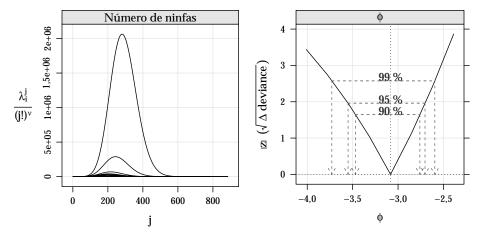
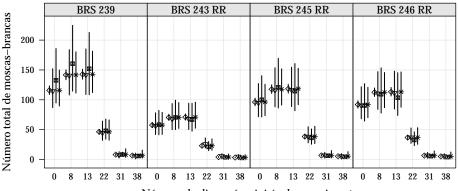


Figura 7: Convergência das constantes de normalização e perfil de log-verossimilhança para o parâmetro de precisão da COM-Poisson.

### Valores preditos





Número de dias após o inicío do experimento

Figura 8: Valores preditos com intervalos de confiança (95%).

#### 4.4

### Resultados e Discussões **Peixes capturados**

#### Estudo

Observacional conduzido por biólogos em um Parque Estadual (UCLA, 2015).

- Delineamento: amostragem aleatória.
- Objetivo: modelar o número de peixes capturados pela atividade de pesca esportiva.
- Unidade experimental: grupos de pescadores visitantes do parque.
- Covariáveis mensuradas:
  - Número de pessoas, (np),
  - ► Número de crianças. (nc),
  - ▶ Indicador de campista no grupo, (ca).
- Variável resposta:
  - Número de peixes capturados pelo grupo.

### Modelagem

#### Preditores considerados:

- Preditor 1:  $g(\mu_i) = \beta_0 + \beta_1 \operatorname{ca}_i + \beta_2 \operatorname{np}_i \\ \operatorname{logit}(\pi_i) = \gamma_0 + \gamma_1 \operatorname{ca}_i + \gamma_2 \operatorname{np}_i + \gamma_3 \operatorname{nc}_i$
- Preditor 2:  $g(\mu_i) = \beta_0 + \beta_1 \operatorname{ca}_i + \beta_2 \operatorname{np}_i + \beta_3 \operatorname{nc}_i + \beta_4 (\operatorname{np}_i \cdot \operatorname{nc}_i) \\ \operatorname{logit}(\pi_i) = \gamma_0 + \gamma_1 \operatorname{ca}_i + \gamma_2 \operatorname{np}_i + \gamma_3 \operatorname{nc}_i + \gamma_4 (\operatorname{np}_i \cdot \operatorname{nc}_i)$

#### Modelos concorrentes:

- ▶ Hurdle Poisson( $\pi_i$ ,  $\mu_i$ )
- ▶ Hurdle COM-Poisson( $\pi_i$ ,  $\lambda_i$ ,  $\phi$ )
- ▶ Hurdle Binomial Negativo( $\pi_i$ ,  $\mu_i$ ,  $\theta$ )

Tabela 4: Medidas de ajuste para avaliação e comparação

Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	
Preditor 1	7	-857,48	1728,96				
Preditor 2	10	-744,58	1509,17	225,79	3	1,1E-48	
Binomial Neg.	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{ heta}$
Preditor 1	8	-399,79	815,58				0,20
Preditor 2	11	-393,72	809,44	12,14	3	0,0069	0,37
COM-Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{\phi}$
Preditor 1	8	-409,85	835,71				-8,77
Preditor 2	11	-402,30	826,59	15,12	3	0,0017	-3,77

Tabela 4: Medidas de ajuste para avaliação e comparação

Poisson	np	$\ell$	AIC	$2(diff \ell)$	diff np	$P(>\chi^2)$	
Preditor 1	7	-857,48	1728,96				
Preditor 2	10	-744,58	1509,17	225,79	3	1,1E-48	
Binomial Neg.	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{ heta}$
Preditor 1	8	-399,79	815,58				0,20
Preditor 2	11	-393,72	809,44	12,14	3	0,0069	0,37
COM-Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{\phi}$
Preditor 1	8	-409,85	835,71				-8,77
Preditor 2	11	-402,30	826,59	15,12	3	0,0017	-3,77

### Valores preditos

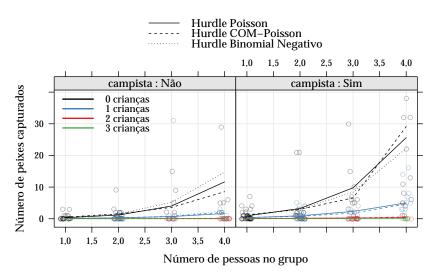


Figura 9: Valores preditos do número de peixes capturados.

#### 4.5

## Resultados e Discussões **Número de nematoides**

### Experimento

Conduzido no IAPAR em casa de vegetação.

- Objetivo: avaliar a resistência de linhagens de feijoeiro à nematoides;
- Delineamento: inteiramente casualizado com cinco repetições;
- Unidade amostral: alíquota de 1ml da solução de raizes lavadas, trituradas, peneiradas, diluídas em água. Provida por um vaso com duas plantas;
- Covariáveis:
  - ▶ Indicador de linhagem de feijoeiro, A, B, C, ..., S, (cult);
  - Concentração de raiz na solução, (sol);
- Variáveis resposta:
  - Número de nematoides.

### Modelagem

#### Preditores considerados:

- ▶ Preditor 1:  $g(\mu_{ij}) = \beta_0 + b_i$
- ► Preditor 2:  $g(\mu_{ij}) = \beta_0 + \beta_1 \log(\text{sol})_{ij} + b_i$

$$b_i \sim \text{Normal}(0, \sigma^2)$$

i: varia entre as linhagens, i = 1, 2, ..., 19; e j: varia entre as observações dentro das linhagens,  $j = 1, 2, ..., n_i$ .

#### Modelos concorrentes:

- ▶ Poisson( $\mu_{ij}$ )
- ► COM-Poisson( $\lambda_{ij}$ ,  $\phi$ )

Tabela 5: Medidas de ajuste para avaliação e comparação

Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$		
Preditor 1 Preditor 2	2	-237,20 -234,00	478,40 474,00	6,40	1	0,0114		
COM-Poisson	np	$\ell$	AIC	$2(diff \ell)$	diff np	$P(>\chi^2)$	$\hat{\phi}$	$P(>\chi^2)$
Preditor 1 Preditor 2	3 4	-236,85 -233,16	479,71 474,31	7,40	1	0,0065	0,15 0,24	0,4060 0,1935

Tabela 5: Medidas de ajuste para avaliação e comparação

Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$		
Preditor 1 Preditor 2	2	-237,20 -234,00	478,40 474,00	6,40	1	0,0114		
COM-Poisson	np	$\ell$	AIC	2(diff $\ell$ )	diff np	$P(>\chi^2)$	$\hat{\phi}$	$P(>\chi^2)$
Preditor 1 Preditor 2	3 4	-236,85 -233,16	479,71 474,31	7,40	1	0,0065	0,15 0,24	0,4060 0,1935

### Avaliação dos perfis de verossimilhança

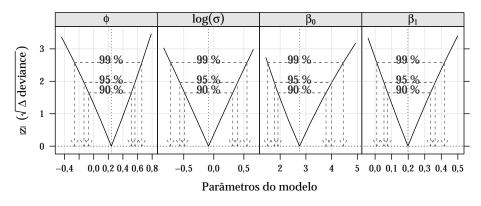


Figura 10: Perfis de verossimilhança dos parâmetros estimados no modelo COM-Poisson Misto.

### Imagem da matriz de covariância

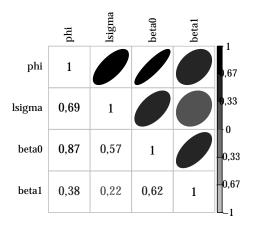


Figura 11: Imagem da matriz de covariância entre os parâmetros do modelo COM-Poisson.

### Valores preditos

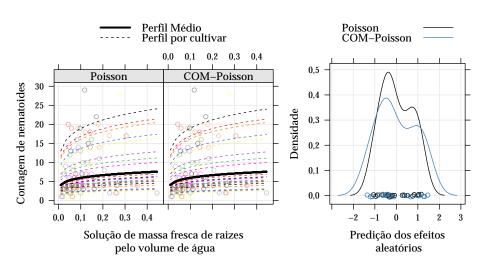


Figura 12: Valores preditos nos modelos de efeitos mistos.

#### 4.6

# Resultados e Discussões **Discussões**

Discussões

- ► Similaridade entre inferências via modelo Quasi-Poisson e COM-Poisson;
- Desempenho do modelo Binomial Negativo;
- Interpretação dos parâmetros nos modelos baseados na COM-Poisson;
- Problemas numéricos para determinação da matriz hessiana no modelo Hurdle COM-Poisson;
- Procedimentos computacionalmente intensivos na avaliação da verossimilhança no caso COM-Poisson de efeitos aleatórios;
- Não ortogonalidade observada (empírica) entre os parâmetros de locação e de precisão no modelo COM-Poisson; e
- $\blacktriangleright$  Comportamento simétrico dos perfis de log-verossimilhança para o parâmetro  $\phi$  da COM-Poisson.

#### 5

## Considerações finais

#### Conclusões

#### Aplicação do modelo COM-Poisson:

- Resultados similares aos providos pela abordagem semi-paramétrica via quasi-verossimilhança;
- A não ortogonalidade entre os parâmetros de locação e precisão no modelo COM-Poisson se mostra como característica da distribuição;
- A simetria nos perfis de verossimilhança do parâmetro de precisão também; e
- ► A avaliação da constante de normalização é uma dificuldade computacional do modelo.

#### Conclusões

#### Análise de dados de contagem:

- Modelo Poisson inadequado na maioria das aplicações, mostrando que a suposição de equidispersão é de fato restritiva;
- Modelos alternativos ao Poisson devem ser empregados na análise de dados de contagem; e
- Sugere-se o modelo COM-Poisson como alternativa totalmente paramétrica e bastante flexível.

#### **Trabalhos futuros**

- Estudar reparametrizações do modelo COM-Poisson;
- Avaliar aproximações da constante de normalização;
- Realizar estudos de simulação para avaliar a robustez do modelo;
- Implementar o modelo COM-Poisson inflacionado de zeros; e
- ▶ Implementar o modelo COM-Poisson com efeitos aleatórios dependentes.

### Publicização



https://github.com/JrEduardo/cmpreg https://github.com/JrEduardo/tccDocument

















#### Referências

CONWAY, R. W.; MAXWELL, W. L. A queuing model with state dependent service rates. **Journal of Industrial Engineering**, v. 12, p. 132—136, 1962.

KOKONENDJI, C. C. Over- and Underdisperson Models. In: **Methods and applications of statistics in clinical trials: Planning, analysis, and inferential methods**. Traducao. [s.l: s.n.]. p. 506–526.

MARTELLI, T. et al. **Influência do ataque de mosca-branca Bemisia tabaci Biotipo B, nos índices de produtividade do algodoeiro**Uberlândia- MGXXII Congresso Brasileiro de Entomologia, 2008.

NELDER, J. A.; WEDDERBURN, R. W. M. Generalized Linear Models. **Journal of the Royal Statistical Society. Series A (General)**, v. 135, p. 370–384, 1972.

SUEKANE, R. DISTRIBUIÇÃO ESPACIAL E DANO DE MOSCA-BRANCA Bemisia tabaci (GENNADIUS, 1889) BIÓTIPO B NA SOJA. PhD thesis—[s.l.] Universidade Federal da Grande Dourados, 2011.

UCLA, S. C. G. Data Analysis Examples, 2015. Disponível em:

<http://www.ats.ucla.edu/stat/dae/>

WINKELMANN, R. Econometric Analysis of Count Data. Traducao. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008. p. 342