Modelo de Regressão COM-Poisson: defoliation

Eduardo E. R. Junior & Walmes M. Zeviani

Esta *vignette*¹ faz parte do trabalho de conclusão de curso em Estatística na Universidade Federal do Paraná que objetiva a exploração de modelos de regressão para variáveis de contagem, por Eduardo Junior sob orientação de Walmes Zeviani.

¹código fonte disponível em https://gitlab. c3sl.ufpr.br/eerj12/tcc_eduardo

Conjunto de dados

O cojunto de dados² contém 125 observações provenientes de um experimento em casa de vegetação inteiramente casualizado com 5 repetições, cujo plantas de algodão (*Gossypium hirsutum*) foram submetidas à níveis de desfolha artificial (5 níveis) combinados com o estágio fenológico da planta na aplicação (5 níveis). As variáveis presente no conjunto de dados são:

- phenol: estágio fenológico durante a aplicação da desfolha (vegetative, flower bud, blossom, boll, boll open);
- defol: nível de desfolha artificial aplicado (0, 0.25, 0.5, 0.75, 1);
- bolls: número de capulhos produzidos ao final da ciclo cultura

Pela Figura ?? notamos a relevância das covariáveis do estudo, pois as curvas de suavização são razoavelmente distintas para cada estágio (phenol) e há uma tendência evidente ao considerar a variação do nível de desfolha (defol) aplicado, em (a) e (b). Além disso, de forma complementar o gráfico em (c) apresenta as médias e variâncias amostrais calculadas nas repetições de cada tratamento e notamos a clara evidência de subdispersão, pois todos os pontos estão abaixo da linha 1 pra 1 que representa a equidispersão.

² Veja detalhes em: Impacto de diferentes níveis de desfolha artificial nos estádios fenológicos do algodoeiro.

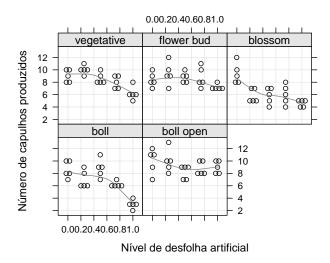
http://www.scielo.mec.pt/pdf/rca/v35n1/ v35n1a16.pdf

Visualizando os dados no R.

```
library(legTools); data(defoliation)
summary(defoliation[, c(1, 2)])
       phenol
                    defol
vegetative:25
                Min. :0.00
 flower bud:25
                1st Qu.:0.25
                Median :0.50
                Mean :0.50
boll
boll open :25
                3rd Qu.:0.75
                Max.
summary(defoliation[, -c(1, 2)])
                bolls
     rept
            Min. : 2.000
 1st Qu.:2
            1st Qu.: 7.000
Median :3
            Median : 8.000
Mean
            Mean
            3rd Qu.: 9.000
```

Encurtando nomes, para facilitar a escrita dos códigos

```
## Estreitando nomes
defol <- defoliation
(names(defol) <- substr(
    names(defoliation), 1, 3))
[1] "phe" "def" "rep" "bol"</pre>
```



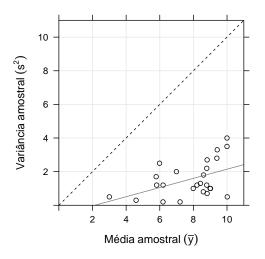


Figura 1: (a) Número de capulhos produzidos pelo nível de desfolha estratificado por estágio da planta. (b) Variâncias em funçãos das médias amostrais calculadas com basa nas 5 repetições de cada tratamento

Modelos propostos

Nesta seção ajustamos modelos estatísticos com 3 diferentes distribuições marginais, [Y | X] associadas, Poisson, Gamma Count³ e COM-Poisson. Para comparação considerou-se o ajuste do modelo quasi-Poisson. Além disso diferentes estruturas para o preditor linear foram consideradas:

- Modelo 0: β_0 (1 parâmetro)
- Modelo 1: $\beta_0 + \beta_1 def$ (2 parâmetros)
- Modelo 2: $\beta_0 + \beta_1 def + \beta_2 def^2$ (3 parâmetros)
- Modelo 3: $\beta_0 + \beta_{1vhe} def + \beta_2 def^2$ (7 parâmetros)
- Modelo 4: $\beta_0 + \beta_{1phe} def + \beta_{2phe} def^2$ (11 parâmetros)

```
<sup>3</sup> As análises foram baseadas em The Gamma-
count distribution in the analysis of experi-
mental underdispersed data
```

http://www.leg.ufpr.br/~walmes/ papercompanions/gammacount2014/papercomp.

```
cpP0 <- glm(bol ~ 1, data = defol, family = poisson)
cpP1 <- <code>glm(bol ~ def, data = defol, family = poisson)</code>
cpP2 \leftarrow glm(bol \sim def + I(def^2), data = defol, family = poisson)
cpP3 <- glm(bol \sim phe:def + I(def^2), data = defol, family = poisson)
       glm(bol \sim phe:(def + I(def^2)), data = defol, family = poisson)
cpQ0 <- glm(formula(cpP0), data = defol, family = quasipoisson)</pre>
    <- glm(formula(cpP1), data = defol, family = quasipoisson)
cpQ2 <- glm(formula(cpP2), data = defol, family =</pre>
                                                     quasipoisson)
    <- glm(formula(cpP3), data = defol, family =
                                                     quasipoisson)
       glm(formula(cpP4), data = defol, family = quasipoisson)
    <- poi2cg(cpP0)
    <- poi2cg(cpP1)
    <- poi2cg(cpP2)
cpG3 <- poi2cg(cpP3)
```

```
cpG4 <- poi2cg(cpP4)
cpC0 <- glm.comp(formula(cpP0), data = defol)
cpC1 <- glm.comp(formula(cpP1), data = defol)</pre>
cpC2 <- glm.comp(formula(cpP2), data = defol)
cpC3 <- glm.comp(formula(cpP3), data = defol)</pre>
cpC4 <- glm.comp(formula(cpP4), data = defol)</pre>
```

```
anova(cpP0, cpP1, cpP2, cpP3, cpP4, test = "Chisq")
Analysis of Deviance Table
Model 1: bol ~ 1
Model 2: bol ~ def
Model 3: bol ~ def + I(def^2)
Model 4: bol ~ phe:def + I(def^2)
Model 5: bol ~ phe:(def + I(def^2))
 Resid. Df Resid. Dev Df Deviance Pr(>Chi)

124 75.514
                  59.650 1 15.8643 6.805e-05 ***
                 58.357 1 1.2926 0.2556
32.997 4 25.3604 4.258e-05 ***
4
         118
                  27.255 4 5.7420 0.2193
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
anova(cpQ0, cpQ1, cpQ2, cpQ3, cpQ4, test = "F")
Analysis of Deviance Table
Model 1: bol ~ 1
Model 2: bol ~ def
Model 3: bol ~ def + I(def^2)
Model 4: bol ~ phe:def + I(def^2)
Model 5: bol \sim phe:(def + I(def^2))
 Resid. Df Resid. Dev Df Deviance
                 75.514
                 59.650 1 15.8643 65.8202 6.343e-13 ***
58.357 1 1.2926 5.3630 0.0223564 *
32.997 4 25.3604 26.3047 1.846e-15 ***
                  27.255 4 5.7420 5.9558 0.0002176 ***
Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
anova.cg(cpG0, cpG1, cpG2, cpG3, cpG4)
          ll npar two.ll.dif npar.dif
1 -272.3961
2 -257.3503
                 3 30.091519
                                       1 4.121296e-08
3 -255.9811
                4 2.738461
                                        1 9.795906e-02
                8 71.671185
4 -220.1455
                                       4 1.007088e-14
5 -208.3865
               12 23.518023
                                       4 9.975695e-05
anova.cmp(cpC0, cpC1, cpC2, cpC3, cpC4)
          ll npar two.ll.dif npar.dif
                                                 pvalue
               2 NA
3 30.031524
1 -272.4794
                                                     NΑ
                                       1 4.250794e-08
1 9.734174e-02
2 -257.4636
                4 2.748565
3 -256.0893
4 -222.5869
                8 67.004730
                                       4 9.726501e-14
  -214.4700
               12 16.233801
                                        4 2.720960e-03
```

Tabela 1: Log-verossimilhanças

	0	•
Modelos	Gamma.Count	COM.Poisson
0	-272.40	-272.48
1	-257.35	-257.46
2	-255.98	-256.09
3	-220.15	-222.59
4	-208.39	-214.47